# Less is More in 3D

## 3D Reconstruction via Frame Selection and Token Merging

김서진, 박준혁, 한지수, 황징아이

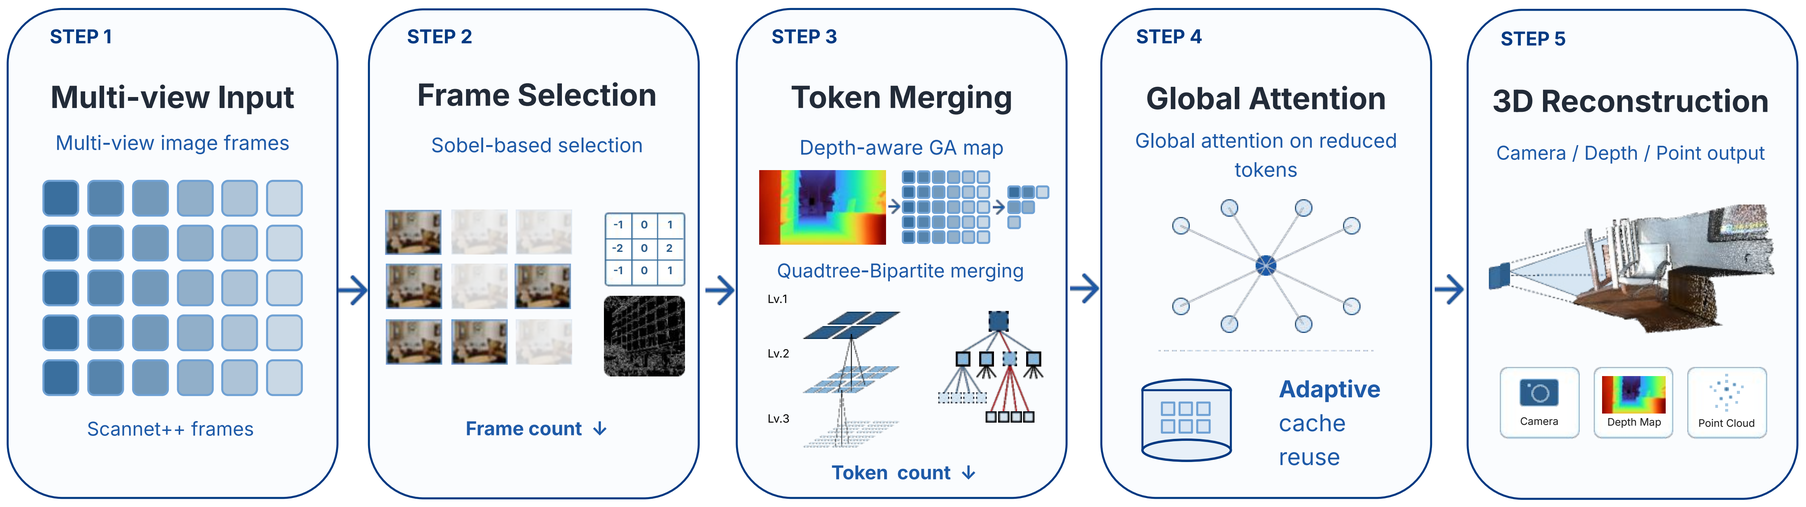
지도교수: 김선주 교수님 | 담당 대학원생: 김민수 | 산학 멘토: 박재웅


## Abstract

**VGGT** 계열 3D reconstruction 모델은 모든 프레임 토큰에 Global Attention을 수행하여 $O((N \cdot T)^2)$의 메모리 복잡도를 가진다. 프레임 수가 증가할수록 OOM(Out-of-Memory) 오류가 발생하는 구조적 한계가 있으며, **LiteVGGT**는 Token Merging으로 이를 부분적으로 완화하였으나 입력 프레임 수 자체는 조절하지 못했다.

본 연구는 **Frame Selection → Token Merging**의 2단계 계층적 프레임워크를 제안한다. Sobel 기반 Frame Selection으로 **정보량이 낮은 프레임을 사전 제거**하고, Quadtree-Bipartite Token Merging과 Depth Boundary Prior, Adaptive Cache Scheduling을 결합하여 **동일한 메모리 예산 내에서 더 많은 프레임을 안정적으로 처리**할 수 있는 확장성을 달성한다.


## Overall Pipeline




## Background

**LiteVGGT Baseline Pipeline**

1. Multi-view RGB frame 전체를 patch token으로 변환
2. Sobel edge map과 local feature variance를 결합해 GA Map 생성
3. GA Map score가 높은 token은 보존(GA token), 나머지는 Destination / Source token으로 분리
4. Source token을 feature similarity가 높은 Destination token에 병합
5. 축소된 token set에 대해 global attention 수행 후 camera, depth map, point map 예측

**Limitation & Motivation**

LiteVGGT에서는 중복 frame까지 Global Attention에 포함된다. 또한 장면 복잡도와 무관하게 고정된 GA token 비율과 hand-crafted GA Map 가중치를 사용한다. 본 연구는 Frame Selection과 Geometry-Aware Token Merging의 계층적 결합을 통해 frame-level redundancy와 token-level redundancy를 함께 줄이고, 제한된 GPU memory 환경에서 LiteVGGT의 확장성을 강화하고자 한다.

## Method

**Exp 1. Information Map based Frame Selection**

LiteVGGT는 모든 입력 frame을 사용하기 때문에 redundant frame까지 Global Attention에 포함되어 GPU memory 부담이 증가한다. 단순 random selection은 중요한 viewpoint를 제거하여 local geometry 손실을 유발할 수 있다.

본 연구는 Token Merging 과정에서 사용되는 Information Map을 frame selection에 활용하였다. 각 frame의 Sobel gradient와 local variance를 결합해 information score를 계산하고, 구조적 정보가 큰 frame을 우선 선택하였다. 이를 통해 redundant frame을 제거하면서도 reconstruction에 필요한 edge 및 local geometry 정보를 보존하도록 하였다.

**Info Score = 0.7 × Sobel gradient + 0.3 × local variance**

**Exp 2. STTM-inspired Quadtree-based Adaptive Token Merging**

LiteVGGT는 고정된 **2×2 stride**로 token을 병합하기 때문에, 단순한 배경 영역에서도 불필요한 token이 유지된다. 본 연구는 Video LLM 가속 기법인 STTM (Multi-Granular Spatio-Temporal Token Merging)의 coarse-to-fine merging 아이디어를 3D reconstruction에 적용하였다. STTM은 큰 block에서 token 유사도를 먼저 확인하고, 유사한 영역은 큰 단위로 병합하며, 복잡한 영역은 더 작은 block으로 분할하여 보존한다. 이를 기반으로 Quadtree-Bipartite Token Merging을 적용하여 단순한 영역은 강하게 압축하고, geometry 변화가 큰 영역은 세밀하게 유지하였다.

**Spatial threshold = 0.9, root block = 8×8, min block = 2×2**

**Exp 3. External Depth Boundary Prior for GA Token Selection**

LiteVGGT의 GA Map은 RGB edge 0.9 + local variance 0.1로 token importance를 계산한다. 그러나 RGB edge는 texture나 조명 변화에도 민감하게 반응하여 실제 geometry와 관련 없는 token을 선택할 수 있다. 이를 보완하기 위해 Depth Anything V2-Small로 depth map을 추정하고, depth 변화가 큰 영역을 depth boundary map으로 변환하였다. 이후 기존 GA score에 depth boundary prior를 작은 비율로 추가하여 object silhouette, surface discontinuity, occlusion boundary와 같은 3D 구조적으로 중요한 token을 더 잘 보존하도록 하였다.

**GA score = 0.9 × RGB edge + 0.1 × local variance + β × depth boundary** (β = 0.08 - 0.10)

**Exp 4. Adaptive Cache Scheduling**

LiteVGGT는 merge indices를 레이어 [0, 6, 15, 20]에서 고정 주기로 재계산하여 장면 복잡도와 무관하게 낭비 또는 부족이 발생한다. 본 연구는 매 레이어마다 dst 토큰의 cosine similarity 변화량 D를 측정하여, 임계값 τ 초과 시에만 재계산하고 그 이하면 이전 merge indices를 재사용한다.

$$D_l = 1 - mean(cos_{sim}(dst_{now}, dst_{cached}))$$

**판단 우선순위: cold_start → forced (layer=0 또는 age ≥ k_max) → drift**

## Result



**Figure 1. ScanNetpp1에 대한 정성적 3D reconstruction 결과 비교.**
이미지는 왼쪽부터 원본 이미지, random 300 frames를 사용한 baseline 결과, selected 300 frames를 사용한 제안 방법 결과, random 600 frames를 사용한 baseline 결과, selected 600 frames를 사용한 제안 방법 결과를 나타낸다.

| Input Frames | Baseline Tokens | Ours Tokens | Reduction | Result |
|---|---|---|---|---|
| **296 (~300)** | 92,648 | **34,632** | **62.6% ↓** | Both Success |
| 600 | 187,800 | **70,200** | **62.6% ↓** | Both Success |
| 900 | OOM | Success | – | **Ours Only** |

**Table 1. Token compression 및 OOM scalability 비교.**

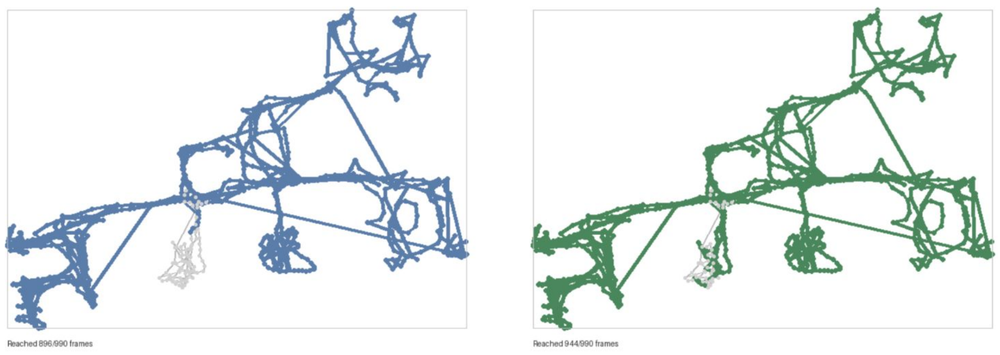



**Figure 2. SMERF long-sequence dataset에서의 trajectory coverage 비교.**

본 실험은 ScanNet++ scannetpp1의 1402-frame long multi-view sequence를 대상으로 수행하였다. 모든 이미지는 350 × 518 해상도로 resize되었으며, patch grid는 25 × 37, frame당 token 수는 총 930개이다. Baseline은 random frame subset을 사용하는 LiteVGGT로 설정하였고, ours는 selected frame 기반의 통합 pipeline으로 설정하였다. 두 방법은 300-frame 및 600-frame budget에서 비교하였으며, 900-frame setting에서는 OOM 발생 여부를 통해 제한된 GPU memory 환경에서의 처리 가능 범위를 확인하였다.

실험 결과, 제안 방법은 동일한 frame budget에서 baseline 대비 merge 후 token 수를 62.6% 추가 감소시켰으며, baseline이 OOM으로 실패한 900-frame setting에서도 실행 가능함을 확인하였다(Table 1). 정성적 결과에서는 일부 fine detail 손실이 존재하지만, 공격적인 token reduction을 적용하면서도 주요 공간 구조를 유지한 reconstruction 결과를 생성하였다(Figure 1). 마지막으로 long-sequence dataset에서 trajectory coverage를 비교한 결과, Baseline은 GPU memory 한계로 인해 마지막 방 영역까지 처리하지 못하고 OOM이 발생한 반면, 제안 방법은 전체 trajectory를 따라 모든 방 영역을 확인할 수 있었다(Figure 2).

따라서 제안 방법은 제한된 GPU memory 환경에서 기존 방법이 처리하기 어려운 large-frame 3D reconstruction의 실행 가능 범위를 확장하는 **memory-scalable reconstruction pipeline**으로 해석할 수 있다. 향후 이러한 memory scalability를 유지하면서 runtime overhead를 줄이고 fine-detail 보존 성능을 개선하는 방향으로 확장할 예정이다.

## Conclusion

- **Sobel Information Map 기반 Frame Selection**을 통해 edge와 geometry 정보를 유지하면서 불필요한 frame을 제거하여, large-scale multi-view 입력에서 발생하는 **OOM 문제를 완화**하였다.
- Quadtree-based Adaptive Token Merging(STTM QT-Bipartite)를 적용하여 더 많은 frame 환경에서도 **안정적인 token compression과 효율적인 global attention 수행 가능성**을 확인하였다.
- **External Depth Boundary Prior**를 추가하여 depth discontinuity와 object boundary를 반영한 **geometry-aware token selection 성능이 향상되었다.**
- **Adaptive Cache Scheduling**을 통해 merge index 재계산을 줄여서 추가적인 연산 효율성과 안정적인 inference를 확보하였다.

즉, 본 연구는 **Frame Selection과 Geometry-aware Token Merging을 계층적으로 결합**하여, **효율성과 reconstruction quality를 동시에 고려한 3D Reconstruction pipeline**의 확장 가능성을 제시한다.